ארכיטקטורה תיאורטית ויישומית למנוע המלצות מבוסס Case-Based Reasoning לאבחון והתערבות בפתולוגיות ארגוניות

פיתוח מנוע DSM ארגוני (Organizational Diagnostic and Statistical Manual) מהווה קפיצת מדרגה קונספטואלית וטכנולוגית באופן שבו ארגונים מאבחנים, מנתחים ומטפלים בכשלים מערכתיים. המעבר ממודל אבחוני דטרמיניסטי וסטטי – המבוסס על הגדרת פרופיל חומרה, חישוב מדד אנטרופיה (Total Entropy Score) ומפת קומורבידיות של פתולוגיות כגון Distorted Reciprocity (DR), Normalization of Deviance (ND) ו-Unrepresentative Calibration (UC) – למערכת דינמית ולומדת, מחייב סינתזה עמוקה. מערכת מבוססת מקרי עבר (Case-Based Reasoning - CBR) הנתמכת בלמידת מכונה (Machine Learning), דורשת שילוב בין חשיבה מערכתית (Systems Thinking), פסיכופתולוגיה רשתית וארכיטקטורת נתונים מודרנית.

מחקר מקיף זה נועד לספק תשתית אדריכלית, תיאורטית ויישומית מקצה לקצה לבניית שכבת ה-CBR וה-Machine Learning מעל ליבת ה-DSM הקיימת. המטרה המרכזית היא לייצר מערכת תומכת החלטה (Clinical Decision Support System - CDSS) בהקשר הארגוני) שמסוגלת לאתר מקרים היסטוריים דומים, להמליץ על התערבויות בעלות אחוזי ההצלחה הגבוהים ביותר עבור קוהורט ספציפי, ולהשתפר באופן תדיר דרך לולאת משוב (Feedback Loop) המכיילת ספים וחוקי החלטה לאורך זמן. המחקר מובנה על פי מתודולוגיית היהלום הכפול (Double Diamond: Discover, Define, Develop, Deliver), תוך שילוב מחקרי חזית מהאקדמיה והתעשייה.

חלק א': שלב הגילוי (Discover) - סקירת ספרות ואינטגרציה תיאורטית

הבסיס למנוע ה-CBR הארגוני נשען על חיתוך בין מודלים של בריאות ארגונית, כלים תומכי החלטה מעולם הרפואה, ותיאוריות מתקדמות של סוציולוגיה, פסיכולוגיה וניהול. הבנת מודלים אלו חיונית לא רק להגדרת המידע הנאסף, אלא להבנת מנגנוני הסיבתיות (Causality) המפעילים את הדינמיקה הארגונית.

1. מודלים לאבחון בריאות ארגונית וכלים תומכי החלטה קליניים

אבחון בריאות ארגונית (Organizational Health) הפך לפרקטיקה קריטית, כאשר ארגונים בריאים מציגים תשואות פיננסיות וביצועים תפעוליים הגבוהים פי שלושה מארגונים לא בריאים.[1] כלים קיימים בשוק מספקים גישות שונות למדידה זו:

- **McKinsey OHI (Organizational Health Index):** מדד זה מבוסס על מסד נתונים של מיליוני תגובות, ובוחן תשע תוצאות בריאותיות (Outcomes) ובין 37 ל-55 פרקטיקות ניהוליות.[2] המודל

מספק תמונת מצב השוואתית (Benchmarking) ומגדיר "מתכונים" (Recipes) להצלחה. עם זאת, הוא נוטה להיות כלי אבחוני תקופתי ולא מנוע החלטות בזמן אמת הבוחן פתולוגיות כרשת.[5]

- **CultureAmp ו-Atlassian Health Monitor:** כלים אלו מתמקדים בסקרי דופק (Pulse Surveys) ומדדי שביעות רצון פשוטים (כגון מודל רמזור או מדד "Nöjd Crispare Index").[6] הם יעילים לזיהוי בעיות נקודתיות ברמת הצוות, אך חסרים את העומק הקליני הנדרש לניתוח כשלים מערכתיים עמוקים כגון סחיפה סמנטית או עקיפת נהלים ממוסדת.

לעומת הכלים הללו, מנוע ה-DSM מציע גישה קלינית. לשם כך, יש לבחון מערכות **Clinical Decision Support Systems (CDSS)** מתחום הרפואה. מערכות CDSS נועדו לצמצם עומס קוגניטיבי, למנוע טעויות אנוש ולהתאים פרוטוקולים טיפוליים על בסיס היסטוריה רפואית והנחיות מבוססות-ראיות.[8] שילוב **Case-Based Reasoning (CBR)** במערכות אלו הוכח כיעיל במיוחד: המערכת מאחזרת תיקים רפואיים קודמים, בוחנת את יעילות הטיפול (למשל, התאמת אנטיביוטיקה על בסיס רגישות החיידק במקרים קודמים), ומייצרת המלצה בעלת הסתברות הצלחה גבוהה.[10]

CBR פועל במחזור של ארבעה שלבים (The 4 R's): **Retrieve** (אחזור מקרים דומים), **Reuse** (שימוש בפתרון הקודם), **Revise** (בחינה והתאמה של הפתרון למקרה החדש), ו-**Retain** (שמירת המקרה החדש כחלק ממסד הנתונים הלומד).[11] העתקת מתודולוגיה זו לעולם הייעוץ הארגוני (Management Consulting Recommender Engine) דורשת הגדרה מחודשת של ה"תיק הקליני" הארגוני, כך שיכיל את דינמיקת הפתולוגיות.

2. דינמיקת הפתולוגיות: מודלים רשתיים וגישות תיאורטיות

ההנחה המחקרית המרכזית בבסיס ה-DSM היא ש-DR, ND ו-UC אינם מדדים מבודדים, אלא רשת סבוכה של השפעות הדדיות. גישה זו שואבת השראה מ**מודלים רשתיים של פסיכופתולוגיה** (Network Models of Psychopathology). בניגוד למודל הרפואי הקלאסי המניח שסימפטומים (למשל נדודי שינה וחרדה) נובעים מישות סמויה אחת (דיכאון), המודל הרשתי גורס כי ההפרעה *היא* הרשת עצמה. סימפטומים מפעילים זה את זה במעגל קסמים (Vicious Cycle), כאשר קיימים "סימפטומי גשר" (Bridge Symptoms) המחברים בין פתולוגיות שונות ויוצרים תחלואה תלויה (Comorbidity).[12] בארגונים, חוסן (Resilience) נמדד ביכולת המערכת לספוג זעזועים רשתיים אלו ולחזור לתפקוד מהיר.[15] מנוע ה-CBR חייב לאתר התערבויות שפירקו את "סימפטומי הגשר" בעבר, ולא רק טיפלו בסימפטום קצה.

2.1 ND (Normalization of Deviance)

הסוציולוגית דיאן וון (Diane Vaughan) טבעה את המונח "נרמול של סטייה" בניתוח שביצעה לאסון מעבורת החלל צ'לנג'ר (1986). התופעה מתארת תהליך הדרגתי בו חריגות מנהלי בטיחות או פרקטיקות תקינות הופכות לנורמה חברתית מקובלת בתוך הארגון, כל עוד אינן גורמות לאסון מיידי.[16] תהליך זה ("The Slow Drift into Failure") מתרחש בשלבי אינקובציה ארוכים, הכוללים הכחשה, סיווג מחדש של סיכונים כקבילים, והעדפת יעילות תפעולית או לחצי ייצור על פני נהלים.[19] ברשת הפתולוגית הארגונית, ND לעולם אינו מתקיים בריק; הוא מתוחזק על ידי סביבה ארגונית חסרת בקרה או סביבה המענישה על הצפת כשלים. מנוע ה-CBR צריך לזהות מתי עקיפת נהלים נובעת מכשל

מערכתי (המצריך שינוי אדריכלי של הנהלים) ומתי היא נובעת מתרבות ארגונית עבריינית.

2.2 Psychological Safety ו- Unrepresentative Calibration (UC)

כיול לא-מייצג (UC) מתאר מצב בו הארגון עיוור למצבו האמיתי, לרוב עקב דיווחי שווא או חוסר יכולת ללמוד מכישלונות. התשתית האקדמית לכך נשענת על עבודתה של אמי אדמונדסון (Amy Edmondson) בנושא ביטחון פסיכולוגי – האמונה המשותפת בצוות כי ניתן לקחת סיכונים בין-אישיים, להודות בטעויות ולחלוק רעיונות ללא פחד מפגיעה בדימוי, ענישה או השפלה.[21] במחקר "Project Aristotle" של חברת גוגל, נמצא כי ביטחון פסיכולוגי הוא המנבא המובהק ביותר להצלחת צוותים ולחדשנות.[21] בהיעדר ביטחון פסיכולוגי, ארגונים גולשים ל"הרמוניה מזויפת" (False Harmony) – פני השטח נראים קוליגיאליים, אך בעיות אמיתיות מוסתרות מחשש לחיכוך.[21] מצב זה מייצר ציון UC גבוה במנוע ה-DSM, שכן נתוני הניהול והבקרה כבר אינם משקפים את המציאות, מה שמוביל לאובדן כושר הלמידה הארגוני.

2.3 Ontological Friction ו- Semantic Drift (פלורידי)

הפער בין מה שארגונים מדווחים לבין מה שקורה בפועל (בבסיס ה-UC) מוסבר היטב על ידי התיאוריות של הפילוסוף לוציאנו פלורידי (Luciano Floridi). פלורידי מתאר את ה"אינפוספירה" (Infosphere) ואת ה"חיכוך האונטולוגי" (Ontological Friction) ככוחות המתנגדים לזרימה והטמעה של מידע.[23] תופעה חמורה במיוחד היא "סחיפה סמנטית" (Semantic Drift), בה מונחים, נהלים או ערכים ארגוניים משנים את משמעותם המעשית לאורך זמן, אף שהמונח עצמו נותר זהה.[25] לדוגמה, נוהל שנקרא "בקרת איכות" עשוי לעבור סחיפה סמנטית ולהפוך לטקס ריק מתוכן שמטרתו אך ורק "לסמן וי" עקב לחצי ND. מנוע ה-CBR הנדרש חייב להיות מסוגל לכמת סחיפה זו על ידי השוואת הצהרות מנהלים למדדי ביצוע אובייקטיביים.

2.4 Double Loop Learning ו- Distorted Reciprocity (DR)

הפתולוגיה השלישית, DR, מתארת מצב של תחרות פנימית הרסנית ומשחקי סכום אפס בין יחידות בארגון. בסביבה כזו, חסימות מידע הופכות לכלי נשק, מה שמשתק את מנגנוני הלמידה. כריס ארגיריס (Chris Argyris) הבחין בין שתי רמות של למידה ארגונית:

- **Single-Loop Learning (למידה חד-לולאתית):** זיהוי שגיאות ותיקון הפעולות בהתאם לחוקים וליעדים הקיימים (כמו תרמוסטט המכוון טמפרטורה).[27]
- **Double-Loop Learning (למידה דו-לולאתית):** זיהוי שגיאות, חקירה ובחינה מחדש של הנחות היסוד, החוקים והערכים השולטים (Governing Variables) שהובילו לפעולה מלכתחילה.[27] כאשר DR גבוה, הארגון מפעיל "שגרות מגננה" (Defensive Routines) ומתנהל על פי "Model I behaviors" – ניסיון למקסם שליטה אישית ולהימנע ממבוכה.[27] הדבר מונע למידה דו-לולאתית, מנציח בעיות מערכתיות, ומחייב את מנוע ה-CBR להמליץ על התערבויות שאינן פרוצדורליות בלבד, אלא כאלו המפרקות את המודלים המנטליים השגויים במערכת (Model II behaviors).

3. מטריקות ביצוע: J-Quotient ו- Decision Latency Index

כדי לאמוד את ה"נזק" שגורמות הפתולוגיות, המנוע משתמש בשני מדדים קריטיים המשמשים גם

כשדות מפתח לאימון מודל ה-ML:

- **Decision Latency Index (DLI):** מדד המכמת את הזמן החולף מרגע שמידע זמין או בקשה להחלטה נוצרת, ועד לרגע שההחלטה מבוצעת בפועל.[29] זהו מדד העוקב אחר "זמן החשיבה" (Thinking delay) בארגון.[29] DLI גבוה מצביע על ביורוקרטיה מסורבלת, פחד מקבלת החלטות (UC/ND נמוך או DR גבוה), וחוסר גמישות (Agility).[29] בעוד שבחברות Agile מצופה DLI של 1-3 ימים, בחברות מסורתיות ציון של למעלה מ-7 ימים מהווה נורמה, המייצרת "הפסד השהיה" עצום (Latency Tax).[29]
- **J-Quotient (מדד קיבולת אבודה):** מכמת את האנרגיה הארגונית, השעות, והתקציב שמתבזבזים על חיכוך מערכתי, עבודה כפולה, ותקשורת לקויה הנובעת מפתולוגיות הרשת.

חלק ב': שלב ההגדרה (Define) - אפיון ה-Feature Space וסכימת ה-DB

כדי לבנות מנוע CBR פעיל, נדרש לתרגם את הנרטיבים, התיאוריות והמדדים שהוצגו למרחב וקטורי מובנה (Feature Space) שיכול להישמר במסד הנתונים ולהיות נגיש למודלי Machine Learning ושליפה וקטורית (Similarity Search).[31]

1. עיצוב ה- Feature Space

האתגר המרכזי של מנוע ה-DSM הוא שמירה על מידע מעורב (Mixed Data Types): ערכים נומריים רציפים, משתנים קטגוריאליים, ומידע טקסטואלי מופשט (Unstructured Text).[31] כל "מקרה" (Case) ייוצג במרחב הפיצ'רים תחת ארבע קטגוריות מרכזיות:

1. **Organizational Context (הקשר ארגוני):** נתונים קטגוריאליים המגדירים את סביבת הארגון. קוהורטים דומים יאפשרו התערבויות דומות. (גודל, תעשייה, סוג מבנה ארגוני).
2. **Pathological Diagnostics (וקטור המצב הרשתי):** הליבה של ה-DSM. ציוני הפתולוגיות (DR, ND, UC) בין 0 ל-10, מדד האנטרופיה המערכתית (Total Entropy Score) המייצג את רמת הכאוס, ופרופיל החומרה הנגזר. שילוב מדדים אלו מאפשר למנוע לזהות רשתות סימפטומים דומות.[12]
3. **Operational Metrics (מדדי נזק תפעולי):** מדד ה-J-Quotient וה-Decision Latency Index (DLI). מדדים אלו משמשים כאינדיקטורים אובייקטיביים המאמתים או סותרים את הציונים הסובייקטיביים של הסקר, ומשמשים לכיול "סחיפה סמנטית" (אם הארגון טוען שהכל תקין אך ה-DLI עומד על 14 ימים, ישנו חיכוך אונטולוגי גבוה).
4. **Semantic & Narrative Embedding (תשובות הזהב):** הייצוג הטקסטואלי של הראיונות ותשובות ה-Policy Engine ("הנרטיב של צוואר הבקבוק"). מידע זה מקודד לתוך וקטור צפוף (Dense Vector Embedding) באמצעות מודלי שפה מודרניים (LLMs), ומאפשר חיפוש על בסיס משמעות עמוקה.[34]

2. סכימת בסיס נתונים (Database Schema) מומלצת

השימוש ב-PostgreSQL בשילוב הרחבת pgvector הוא פרקטיקה תעשייתית מובילה למערכות

היברידיות מסוג זה. הוא מאפשר שמירת מידע רלציוני לצד ביצוע פעולות אלגברה וקטורית באותה שאילתה.[35] הסכימה הבאה מפרידה בין המבנה הארגוני, תיעוד האבחון, ותיעוד ההתערבויות ולולאת הפידבק.

טבלה 1: organizations_context

מכילה נתוני מאקרו בלתי משתנים (או משתנים לאט) על הארגון.

עמודה	סוג נתונים	תיאור
org_id	UUID (PK)	מזהה ייחודי של הארגון במערכת.
industry_sector	VARCHAR	מגזר הפעילות (למשל: Fintech, Healthcare, Manufacturing).
employee_size_band	VARCHAR	סיווג גודל קטגוריאלי (למשל: 10-50, 51-200, 201-1000).
culture_archetype	VARCHAR	סיווג סגנון הניהול ההיסטורי (למשל: Agile, Hierarchical, Matrix).

טבלה 2: dsm_diagnostic_snapshots

מתעדת את תמונת המצב הדיאגנוסטית בכל רגע נתון שבו מבוצע סקר או מדידה. כל רשומה היא "מקרה" בסיסי לאחזור.

עמודה	סוג נתונים	תיאור
snapshot_id	UUID (PK)	מזהה ייחודי של האבחון.

org_id	(UUID (FK	קישור לארגון.
created_at	TIMESTAMP	מועד האבחון (חיוני למעקב אחר התדרדרות או למידה).
score_dr	FLOAT	רמת התחרות הפנימית ומשחקי סכום אפס (0-10).
score_nd	FLOAT	רמת נרמול הסטייה ועקיפת הנהלים (0-10).
score_uc	FLOAT	רמת העיוורון המערכתי והסחיפה הסמנטית (0-10).
total_entropy	FLOAT	מדד אי-הסדר והיציבות הרשתית (חישוב נגזר).
j_quotient	FLOAT	הערכת הקיבולת האבודה (פסד כספי/תפוקה).
decision_latency	FLOAT	מדד DLI מחושב בימים (קצב קבלת החלטות).
severity_profile	VARCHAR	קטגוריית הסיכון (Healthy, At-risk, Critical, Systemic-collapse).

bottleneck_text	TEXT	תשובת הזהב המסכמת את הנרטיב העיקרי (Policy Layer).
feature_vector	VECTOR(1536)	וקטור משולב (Tabular + Textual) התומך באחזור מהיר דרך pgvector.

טבלה 3: interventions_and_feedback

טבלה המקשרת בין האבחון לבין הפעולה הקלינית שבוצעה בפועל, וקולטת את המשוב והתוצאות. זוהי התשתית של לולאת ההתערבות.

עמודה	סוג נתונים	תיאור
intervention_id	UUID (PK)	מזהה ייחודי של מהלך ההתערבות.
snapshot_id	UUID (FK)	קישור לאבחון ה-DSM הספציפי שעל בסיסו התקבלה ההחלטה.
recommended_cta	VARCHAR	ההתערבות שהמערכת המליצה (למשל: NOD→BIA, Sprint).
consultant_override	BOOLEAN	דגל (Flag): האם היועץ דחה את המלצת המערכת והחליף אותה?
actual_cta	VARCHAR	ההתערבות שבוצעה בפועל.

override_reason	TEXT	טקסט חופשי: מדוע היועץ שינה את ההחלטה? (קריטי ללמידה מחיזוקים).
followup_date	TIMESTAMP	מועד מדידת ה-DSM העוקבת (לרוב 3-6 חודשים לאחר ההתערבות).
delta_entropy	FLOAT	השינוי באנטרופיה המערכתית (תוצאה שלילית = שיפור / התייצבות).
delta_j_quotient	FLOAT	השינוי בקיבולת הארגונית (כמה "כסף" נחסך).
success_label	BOOLEAN/FLOAT	תיוג סופי להצלחת ההתערבות (לשימוש במודל Machine Learning עתידי).

עיבוד הוקטור המשולב (Tabular Embeddings): שדה ה-feature_vector יהווה שילוב חכם. מאחר ומודלי שפה סטנדרטיים (LLMs) מתקשים לעיתים לייצג יחסים כמותיים עדינים [37], הפרקטיקה המומלצת היא לשרשר וקטור של נתונים נומריים מנורמלים (DR, ND, UC, DLI) לתוך וקטור הקידוד הטקסטואלי (Text Embedding) המופק מתיאור המקרה.[39] גישה זו מבטיחה שהמשמעות הסמנטית והחומרה המספרית יילקחו בחשבון יחד במהלך חיפוש הדמיון.

חלק ג': שלב הפיתוח (Develop) - מנגנוני ליבה ואלגוריתמיקה

עיצוב המערכת משלב מספר מנועים הפועלים בסנכרון. הלב הפועם של המערכת הוא מעבר מחיפוש דטרמיניסטי לחיפוש הסתברותי וסטטיסטי המבוסס על אבחון קליני.

1. עיצוב מנגנון הדמיון (Similarity / Retrieval)

במערכת המכילה מידע מעורב (נומרי, קטגוריאלי, וטקסטואלי), לא ניתן להסתמך על מטריקת מרחק אחת בלבד.[39]

בחירת מטריקות המרחק

1. **מרחק אוקלידי (Euclidean Distance / L2):** רלוונטי במיוחד לחלק הכמותי של הפתולוגיות. ארגון עם ציונים של $DR = 9, ND = 2$ שונה מהותית אלינית מארגון עם $DR = 2, ND = 9$, והמרחק האוקלידי במרחב התלת-ממדי (DR, ND, UC) מדגיש פערים אלו בדיוק רב.[31]
2. **מרחק גוור (Gower Distance):** מטריקה קלאסית המתמודדת היטב עם נתונים מרובי-סוגים על ידי הפעלת חישוב שונה לכל סוג נתון וסיכומם (למשל, 0 או 1 להתאמה קטגוריאלית של מגזר).[39] למרות התיאוריה המוצקה, יישום Gower במערכות DB מסורבל חישובית בקנה מידה גדול.
3. **דמיון קוסינוס (Cosine Similarity):** הסטנדרט דה-פקטו במודלים מבוססי Embeddings המנתחים טקסט רציף ונרטיבים של חקר מקרה.[32] מדד זה בוחן את הזווית בין הוקטורים, מה שהופך אותו לאידיאלי לאיתור הקשרים סמנטיים (למשל, כאשר שתי חברות מדווחות על סחיפה סמנטית בנהלים, גם אם המילים אינן זהות).[40]
4. **מטריקה נלמדת (Learned Metric):** בשלבים מתקדמים, רשתות נוירונים צמודות (Siamese Networks) יוכלו ללמוד פונקציית מרחק המותאמת אישית, שמשקללת אילו תכונות באמת מנבאות הצלחת טיפול משותפת, תוך התגברות על רעש מערכתי.[43]

מנגנון השקלול ההיברידי (Hybrid Search)

הפרקטיקה המומלצת בשלב ה-MVP היא שילוב (Ensemble) של סינון קשיח וחיפוש וקטורי רך:

$$Similarity(C_{new}, C_{historical}) = \alpha \cdot L2(DSM_{new}, DSM_{historical}) + \beta \cdot Cosine(Emb_{new}, Emb_{historical})$$

כאשר הסינון מראש (Pre-filtering) יבטיח שהשוואה מבוצעת רק בתוך אותו מגזר (Industry) ואותה רמת חומרה (Severity Profile), כדי למנוע השוואת סטארט-אפ קטן לארגון פדרלי ענק. משקל גבוה (α) יינתן לקרבה במדדי הפתולוגיות וקיבולת J-Quotient, שכן הם ה-Governing Variables של המשבר.[27]

תשתיות טכנולוגיות: pgvector מול FAISS

בעת בחירת מנוע החיפוש הוקטורי, יש להכריע בין ספריית ביצועים קיצונית למסד נתונים אחוד:

- **FAISS (מבית Meta):** ספריה זו היא הסטנדרט המהיר ביותר לחיפוש במיליוני וקטורים באמצעות Quantization.[44] עם זאת, FAISS חסרה יכולות ניהול נתונים (CRUD) וחשוב מכך – היא חלשה מאוד ב-**Filtered Vector Search**.[35] אם עלינו לאחזר מקרים אך ורק מארגונים עם

$DLI > 10$, חיפוש דרך FAISS ידרוש Post-filtering שעלול להשאיר אותנו ללא תוצאות מספיקות (פגיעה משמעותית ב-Recall).[46]

- **pgvector ב-PostgreSQL/Supabase:** ההרחבה מאפשרת שילוב הדוק בין שאילתות SQL לוגיות לחיפוש דמיון וקטורי באותה טרנזקציה.[35] עבור מערכות ייעוץ עסקי (B2B), שבהן היקף הרשומות עומד לרוב על אלפים עד עשרות אלפים (ולא מיליארדים), pgvector מספק ביצועים מצוינים, יציבות (ACID compliance) ופשטות ארכיטקטונית.[36] שימוש באינדקס **HNSW** (Hierarchical Navigable Small World) בתוך pgvector יבטיח אחזור מקורב ומהיר.[36] לפיכך, **pgvector נבחר כתשתית האופטימלית למערכת.**

2. עיצוב מודול ההמלצה (Recommendation Engine)

לאחר שמנגנון ה-Retrieval שלף את K המקרים הדומים ביותר (Top-K, למשל $K = 15$), מודול ההמלצה נדרש לסנתז נתונים אלו להנחיה מעשית עבור היועץ.

שלב 1: הצגת סטטיסטיקה תיאורית ישירה

עבור כל התערבות (למשל, "NOD→BIA", "Learning Exercise") שהופעלה ב- K המקרים שנשלפו, המערכת תחשב מתוך נתוני ה-Follow-up:

- **Success Rate (שיעור הצלחה):** אחוז המקרים שבהם ההתערבות הובילה לירידה באנטרופיה המערכתית ($\Delta TotalEntropy < 0$) או לשיפור משמעותי במדד ה-J-Quotient.
- **Confidence Interval (רווח בר-סמך):** תרגום ודאות סטטיסטית. התערבות שהצליחה ב-3 מתוך 3 מקרים היא בעלת שונות גבוהה מדי מכדי להיחשב אמינה באופן מוחלט, בעוד שהתערבות שהצליחה ב-16 מתוך 20 מקרים תקבל ציון Confidence גבוה (שימוש בנוסחת Wilson Score למדדים פרופורציונליים).[49]

הפלט המוצג ליועץ ייראה כך:

Top Recommended Intervention: NOD→BIA

Success Rate in similar cohort: 78% (Based on 14 cases)

Expected Outcome: Reduction in Decision Latency by ~3.5 days, J-Quotient recovery of ~12%.

Alternative 1: Blame→Reporting (Success: 60%, Confidence: Low)

שלב 2: למידת מכונה פרידיקטיבית

כאשר מאגר המידע יגיע למסה קריטית (מעל 1,000 מקרי אבחון ומעקב), המערכת תעבור מסטטיסטיקה תיאורית למודל למידת מכונה מסוג חיזוי (Predictive Classification). המודל המומלץ להתחלה הוא **Gradient Boosting (כגון XGBoost)** או **Logistic Regression**. מודלים מבוססי עצים (Tree-based models) מצטיינים במיוחד בעיבוד נתונים טבלאיים ומעורבים (Tabular Data),

מתמודדים היטב עם ערכים חסרים (Missing values) ומספקים הסבריות (Explainability) גבוהה – יכולת קריטית במערכות תומכות החלטה.[50] המודל יקבל כקלט את וקטור המצב של הארגון וסוג ההתערבות, ויפלוט את ההסתברות $P(Success)$ לאותה פעולה.

3. לולאת משוב ולמידה מתמדת (Feedback Loop & Continuous Learning)

כדי לייצר ארגון לומד ולמנוע קיפאון אלגוריתמי, המערכת משתמשת בעקרונות הלמידה הדו-לולאתית (Double Loop Learning) של ארגיריס ברמת האלגוריתם עצמו.[27]

איסוף משוב מיועצים (Human-in-the-Loop)

היועץ לעולם אינו מקבל את המלצת האלגוריתם כתורה מסיני. המערכת מחייבת מעורבות אנושית לאישור ה-CTA. אם היועץ מחליט כי ההמלצה אינה מתאימה להקשר הארגוני הייחודי (שאינו משתקף בנתונים, כגון משבר אימון אישי נקודתי), הוא מבצע **Override**. שדות ה-Override (תיעוד הפעולה החדשה וטקסט הסיבה החופשי) נשמרים בטבלת interventions_and_feedback. עם הזמן, המערכת מזהה אילו פרופילים מובילים לפסילת המלצותיה ולומדת מכך (Active Learning).[51]

כיול בייסיאני של ספים וחוקים (Bayesian Calibration)

שכבת ה-Policy ההתחלתית במנוע מבוססת על חוקים דטרמיניסטיים מוגדרים מראש (Heuristic DECISION_RULES). לדוגמה: *אם הציון של UC הוא מעל 8, המלץ על "Learning Exercise"*. עם הצטברות נתוני Follow-up (כגון שינויים ב-J-Quotient וב-DLI), המערכת עושה שימוש בעדכון בייסיאני כדי לכייל ספים אלו.[54] התהליך פועל כך:

1. **Prior (אמונה מוקדמת):** ההסתברות שחוק מסוים יוביל להצלחה (נקבעה מראש על ידי מהנדסי המערכת).
2. **Likelihood (נראות):** העדויות החדשות מן השטח - אחוזי ההצלחה בפועל של הכלל בסביבות שונות.
3. **Posterior (אמונה מעודכנת):** שקלול של ה-Prior וה-Likelihood.

אם המערכת מזהה כי התערבות בחברות Healthcare שבהן $ND > 7$ נכשלת פעם אחר פעם למרות החוק הראשוני, ההסתברות הבייסיאנית של הכלל תתעדכן כלפי מטה. אלגוריתם הכיול יעדכן בצורה דינמית את משקולות ה-Feature Space (הגדלת חשיבות ה-Industry) או ימליץ למנהל המערכת להזיז את הסף ההיוריסטי מ-7 ל-9.[53] תהליך זה הוא הפתרון הישיר להתמודדות עם ה**סחיפה הסמנטית (Semantic Drift)** אותה תיאר פלורידי: בארגונים מסוימים, המשתתפים לומדים עם הזמן לענות על סקרי ה-DSM בצורה "מנורמלת", והציונים (UC/ND) מתחילים לאבד קורלציה עם המציאות האובייקטיבית.[25] הלולאה הבייסיאנית המצליבה דיווחי שאלון עם מדידת DLI אובייקטיבית תזהה את הסחיפה ותעדכן את חומרת האבחון בהתאם.

חלק ד': שלב המסירה (Deliver) - ארכיטקטורה מערכתית והמלצות מעשיות

כדי לאפשר מעבר מיישום תיאורטי למוצר עובד (MVP), הארכיטקטורה המערכתית מחולקת לרכיבי Microservices או מודולים עצמאיים לחלוטין.

1. תרשים ארכיטקטורה עליונה (High-Level Architecture)

קטע קוד

```
graph TD
%% Client Tier
Client

%% API Layer
API
Client <-->|REST / GraphQL| API

%% Engines
subgraph Core Engines
DSM
POL
CBR
end

API -->|Raw Q&A Data| DSM
DSM -->|DR/ND/UC/Entropy Scores| POL
DSM -->|Snapshot Data| CBR
POL -->|Initial Bottleneck Narrative| CBR

%% Database & Vector Store Layer
subgraph Data Infrastructure
DB
DB_VEC
DB_LOG[(Followup & Feedback Log)]
end

DB --- DB_VEC
DB --- DB_LOG
```

```
%% Data Flow Interactions
DSM <-->|Save Snapshots| DB
POL <-->|Fetch Deterministic Rules| DB
CBR <-->|1. Top-K Similarity Search| DB_VEC
CBR <-->|2. Fetch Historical Outcomes| DB

%% Feedback Loop Flow
API -.->|Consultant Override & Outcome Δ| DB_LOG
DB_LOG -.->|Recalibrate Bayesian Weights| CBR
DB_LOG -.->|Suggest Rule Threshold Updates| POL
```

2. המלצות מעשיות לבניית ה-MVP

בניית מודל נתונים מורכב עלולה לגרור Over-engineering מוקדם. יש להתקדם בגישה מדורגת:

- **שלב 1: איסוף והבניית נתונים (Data & Pipeline):**
הקמת מסד הנתונים PostgreSQL עם סכמת הטבלאות שהוצגה מעלה. הפעלת מנגנון איסוף אגרסיבי של כל מקרי העבר הקיימים (גם אם ידרשו תיוג רטרואקטיבי ידני של אבחונים קודמים ותוצאות ההתערבות בהם). בשלב זה המערכת פועלת רק על בסיס ה-Policy Engine הדטרמיניסטי.
- **שלב 2: וקטוריזציה ואחזור (Vectorization & Retrieval):**
הטמעת pgvector. יצירת מנגנון (Cron Job או Trigger) הממיר כל דוח אבחון ל-Embedding ושומר אותו. כתיבת פונקציית SQL המאפשרת לאחזר "מקרים דומים".
- **שלב 3: מנוע המלצות סטטיסטי (Statistical Recommender):**
בניית פונקציה שעוברת על המקרים שאוחזרו (Top-K) ומייצרת אגרגציה פשוטה (Success Rate למעשה) המציגה ליועץ את החלופות. הוספת טפסי Override *בממשק המשתמש* (UI).
- **שלב 4: למידת מכונה פרידיקטיבית (Advanced ML):**
לאחר צבירת מאות/אלפי פידבקים ותוצאות פולו-אפ – מעבר מסטטיסטיקה תיאורית לאימון מודל XGBoost וכיול בייסיאני.

3. סיכונים צפויים ואסטרטגיות התמודדות

1. **Data Sparsity (מחסור בנתונים / התחלה קרה):**
בתחילת הדרך, קוהורט ספציפי עשוי להכיל מקרים מועטים, מה שמוביל להחלטות חסרות משמעות סטטיסטית.
הפתרון: המערכת תסמן כל המלצה במדד Confidence (מרווח סמך). אם הערך נמוך מסף מסוים (למשל, פחות מ-5 מקרי אמת היסטוריים), מנוע ה-CBR ידמם ויוצג רק הפלט של ה-Policy Engine הישן כאמצעי גיבוי פול-באק (Fallback).
2. **Overfitting (התאמת יתר של מודלים) ו- Bias:** המודל עלול לפתח הטיות (Bias), למשל להמליץ תמיד על התערבות של "Live Demo" פשוט כי היא בוצעה הכי הרבה פעמים, ולאו דווקא כי היא היעילה ביותר (Popularity Bias).[56] *הפתרון:* שימוש בפונקציות ענישה (Penalization) להתערבויות פופולריות, וכיול בייסיאני שבוחן את *יחס ההצלחות* בלבד, תוך נרמול השפעת גודל

המדגם.[56]

3. **Privacy (פרטיות לקוחות):**
אחזור נתוני לקוח מובהקים והצגתם ליועץ במקרה של חברה מתחרה עלול לחשוף מידע מסחרי רגיש ואסטרטגי (Ontological friction בהקשרי שקיפות נתונים).
הפתרון: המערכת לא תחזיר טקסט קריא של מקרים מזהים. היא תחזיר תמצות אלגוריתמי אנונימי ברמת "ארגון פיננסי בינוני עם UC קיצוני ו-DLI של 10 ימים, ביצע Sprint ששיפר את מצבו ב-30%". ניתן לממש זאת באמצעות מדיניות Row-Level Security (RLS) במסד הנתונים.

4. יישום מעשי: דוגמאות קוד ושילוב (Code Examples)

כדי לתמוך בפונקציונליות השאילתות הנדרשת בעזרת pgvector, תוך ביצוע סינון קשיח מוקדם (Filtered Similarity Search), להלן פונקציית SQL מתקדמת היושבת במסד הנתונים.[36]

דוגמת קוד SQL ליצירת פונקציית חיפוש דמיון משוקללת ב-PostgreSQL:

SQL

```
CREATE OR REPLACE FUNCTION get_similar_cases_with_stats(
query_embedding vector(1536),   -- Embedding produced by LLM representing text+numeric state
target_industry varchar,        -- Hard filter: Industry Cohort
max_dli float,                  -- Hard filter: Max Decision Latency Threshold
match_limit int DEFAULT 10
)
RETURNS TABLE (
case_id uuid,
intervention_type varchar,
delta_total_entropy float,
j_quotient_recovered float,
similarity_score float
)
LANGUAGE plpgsql
AS $$
BEGIN
RETURN QUERY
SELECT
c.case_id,
i.actual_cta AS intervention_type,
i.delta_entropy AS delta_total_entropy,
i.delta_j_quotient AS j_quotient_recovered,
-- Calculate Cosine Similarity Score (1 - Cosine Distance)
```

```
    1 - (c.feature_vector <=> query_embedding) AS similarity_score
    FROM dsm_diagnostic_snapshots c
    JOIN interventions_and_feedback i ON c.snapshot_id = i.snapshot_id
    JOIN organizations_context o ON c.org_id = o.org_id
    WHERE
    -- Pre-filtering based on Cohort criteria to ensure context relevance
    o.industry_sector = target_industry
    AND c.decision_latency <= max_dli
    -- Ensure the historical case has follow-up data (is a 'closed loop' case)
    AND i.followup_date IS NOT NULL
    -- Perform Approximate Nearest Neighbor (ANN) search via HNSW index on the vector
    ORDER BY c.feature_vector <=> query_embedding
    LIMIT match_limit;
;END
;$$
```

דוגמת פסיאודו-קוד ב-TypeScript לבניית האנדפוינט ההמלצתי (API Endpoint):

TypeScript

```
import { SupabaseClient } from '@supabase/supabase-js';
import { generateEmbedding } from './ml_service';

export async function getInterventionRecommendation(
  supabase: SupabaseClient,
  currentDsmSnapshot: DiagnosticSnapshot
) {
  // 1. Generate combined tabular + textual embedding for the current state
  const embeddingVector = await generateEmbedding({
    dr: currentDsmSnapshot.score_dr,
    nd: currentDsmSnapshot.score_nd,
    uc: currentDsmSnapshot.score_uc,
    j_quotient: currentDsmSnapshot.j_quotient,
    narrative: currentDsmSnapshot.bottleneck_text
  });

  // 2. Fetch Top-K similar cases matching the specific cohort via RPC
  const { data: similarCases, error } = await supabase.rpc('get_similar_cases_with_stats', {
    query_embedding: embeddingVector,
    target_industry: currentDsmSnapshot.orgContext.industry_sector,
```

```
max_dli: currentDsmSnapshot.decision_latency * 1.5, // Allow some margin
match_limit: 15
});

if (error ||!similarCases |

| similarCases.length === 0) {
throw new Error("No sufficient data for CBR. Fallback to Policy Engine.");
}

// 3. Aggregate Stats to determine success rates and build recommendation logic
const interventionStats = similarCases.reduce((acc, row) => {
if (!acc[row.intervention_type]) {
acc[row.intervention_type] = { count: 0, successfulCount: 0, totalJRecovered: 0 };
}
acc[row.intervention_type].count += 1;

// Heuristic Definition of Success: Entropy dropped by > 1.5 or significant J-Quotient recovery
if (row.delta_total_entropy < -1.5 |

| row.j_quotient_recovered > 150000) {
acc[row.intervention_type].successfulCount += 1;
acc[row.intervention_type].totalJRecovered += row.j_quotient_recovered;
}
return acc;
}, {} as Record<string, any>);

// 4. Format and sort recommendations based on success probabilities
const recommendations = Object.entries(interventionStats).map(([type, data]) => {
const successRate = data.successfulCount / data.count;
// Using simplistic confidence evaluation for the MVP
const confidence = data.count > 5? 'High' : (data.count > 2? 'Medium' : 'Low');
const avgROI = data.successfulCount > 0? (data.totalJRecovered / data.successfulCount) : 0;

return {
intervention: type,
success_rate_percent: (successRate * 100).toFixed(1),
average_roi_saved: avgROI,
confidence_level: confidence,
data_points: data.count
};
}).sort((a, b) => parseFloat(b.success_rate_percent) - parseFloat(a.success_rate_percent));
```

```
// Return the best option alongside the deterministic baseline
return {
  primary_recommendation: recommendations,
  alternative_options: recommendations.slice(1),
  policy_engine_baseline: await getDeterministicRule(currentDsmSnapshot
  )
};
}
```

סיכום

אדריכלות המערכת המוצעת מהווה קפיצת דרך במדע הניהול. היא ממירה אבחונים פסיביים למערכת עצה והכוונת פעולה דינמית (CDSS) שמוכיחה את עצמה דרך נתונים קליניים ארגוניים. על ידי שימוש בפרקטיקות CBR מתקדמות, גישור המרחק הוקטורי בעזרת pgvector, וכינון לולאת פידבק בייסיאנית (Bayesian Calibration), המנוע מפרק את המנגנונים ההרסניים של נרמול הסטייה, חיכוך אונטולוגי וסחיפה סמנטית. המערכת לא רק מזהה היכן הבעיה מתרחשת, אלא שופכת אור אמפירי על אילו פעולות, בסבירות הגבוהה ביותר, יפרקו את רשת הפתולוגיות, יקצרו את זמן ההשהיה (Decision Latency) ויחזירו קיבולת עצומה לארגון – תוך שהיא הופכת אנושית ולומדת מההתערבויות שהיא עצמה מייצרת.

נספח: רשימת מקורות מרכזיים (Citations) ויישומיות למערכת ה-DSM

רשימה זו מאגדת את גופי הידע התיאורטיים והטכנולוגיים שעליהם מבוסס האפיון, תוך הדגשת החיבור המעשי למנגנון ה-DSM.

מחבר (ושנה)	רעיון מרכזי מוביל	אופן השימוש והיישום בתוך מנוע ה-DSM	קישוריות (IDs)
Vaughan, D. (1996, 2016)	*Normalization of Deviance (ND)*: תהליך בו חריגות וסימני אזהרה מתקבלים כנורמה חברתית וכסיכון קביל לאורך "תקופת אינקובציה" איטית וארוכה עד לכשל	משמש כבסיס תיאורטי לפתולוגיית ה-ND. המערכת בוחנת (DLI через וקומורבידיות) האם התרבות מנרמלת עקיפת תהליכים ומייצרת מדד סיכון עוד בטרם מתרחש	17

	המערכתי.[17]	אסון ארגוני.[17]	
Edmondson, A. C. ((1999, 2024	*Psychological Safety*: אמונה משותפת בסביבה ארגונית כי לקיחת סיכונים בין-אישיים, ביטוי חששות והודאה בטעויות לא יובילו לענישה.[21] הוכח כמנבא מספר אחד לצוותי ביצועים.[21]	אינדיקטור מרכזי בפרופיל ה-UC (עיוורון ארגוני). מנוע ה-CBR מכייל התערבויות המשקמות סביבות "הרמוניה מזויפת", תוך העלאת היכולת לדון בצווארי הבקבוק בצורה פומבית.	21
Argyris, C. (1977, (1996	*Double-Loop Learning*: הבחנה בין פתרון בעיות שטחי תחת משתנים שולטים קיימים (Single-loop), לבין שינוי תהליכי עומק בו הנחות המוצא והנורמות נבדקות (Double-loop).[27]	הפתולוגיה של DR מקדמת התנהגות מגננתית מובהקת המונעת למידה דו-לולאתית.[27] המערכת בוחנת האם ההתערבות המומלצת מעודדת שינוי הנחות יסוד.	27
Floridi, L. (2004, (2016	*Ontological Friction & Semantic Drift*: חיכוך אונטולוגי המעכב מעבר מידע, וסחיפה סמנטית בה מונחים קריטיים בארגון מדולדלים או משנים משמעות עקב לחצים מוסדיים.[23]	מנוע ה-Feedback מזהה סחיפה זו: כשהארגון מדווח סטטוס תקין אך מדד ה-DLI מזנק, המערכת מכיילת ספים (בייסיאנית) כדי למנוע הישענות על מילים ארגוניות שאיבדו ממשמעותן.	23
Borsboom, D. et al. ((2010, 2017	*Network Models of Psychopathology*: הבנה קלינית שהפרעות נפשיות הן רשת של סימפטומים	משמש כתפיסה האדריכלית של ה-Total Entropy ומפת הקומורבידיות. התערבויות (Interventions)	12

	המשפיעים זה על זה, ולא ישויות עצמאיות או סמויות.[12]	ב-CBR מוערכות על פי יכולתן לפרק "סימפטומי גשר" (Bridge symptoms) ברשת הפתולוגית.[12]	
McKinsey & Co. (2003-2025)	*Organizational Health Index (OHI)*: מדידת 9 תוצאות ו-37+ פרקטיקות. מספק רפרנס שארגונים בריאים מנצחים כלכלית ארגונים חולים פי 3, ומוכיח שניתן לכמת בריאות דרך Benchmarking.[1]	מספק הוכחת היתכנות (Proof of Concept) והשראה עסקית לייצוג המצב הדיאגנוסטי כסדרה של ממדים טבלאיים המנבאים יעילות (J-Quotient) לאורך זמן במודלי ה-Machine Learning.[2]	[1]
Aamodt, A., & Plaza, E. (1994)	*Case-Based Reasoning*: תהליך קוגניטיבי וממוחשב הכולל ארבעה שלבים לפתרון בעיות חדשות על בסיס התאמתן לבעיות עבר היסטוריות (Retrieve, Reuse, Revise, Retain).[11]	זוהי הליבה האלגוריתמית של שכבת החדשנות. עיצוב ה-Vector space, בניית פונקציית מרחק היברידית, ויישום לולאת למידה מתמדת באמצעות שמירה מחודשת של ה-Outcomes בבסיס הנתונים.	[10]
Hackathorn, R. (2004) / Agile	*Decision Latency Index (DLI)*: מטריקה ביצועית עסקית לזמן החולף בין היווצרות הנתונים/הדרישה, לבין קבלת ההחלטה והפעולה. מדד מרכזי לאג'יליות והעלות החבויה בארגון.[29]	משמש הן כמשתנה במרחב ההקשר (Context Vector) לחיפוש דמיון, והן כמדד תוצאה קריטי. התערבויות (כגון Sprints) מוערכות ביכולתן לחתוך את זמן ה-Latency כאינדיקציה לניקוי ביורוקרטיה.[29]	[29]

עבודות שצוטטו

1. Organizational Health Index | McKinsey & Company, נרשמה גישה בתאריך מרץ 17, 2026, https://www.mckinsey.com/solutions/orgsolutions/overview/organizational-health-index
2. Organizational health: A fast track to performance improvement - McKinsey, נרשמה גישה בתאריך מרץ 17, 2026, https://www.mckinsey.com/capabilities/people-and-organizational-performance/our-insights/organizational-health-a-fast-track-to-performance-improvement
3. How OHI works | McKinsey & Company, נרשמה גישה בתאריך מרץ 17, 2026, https://www.mckinsey.com/solutions/orgsolutions/overview/organizational-health-index/how-ohi-works
4. Organizational Health Index (OHI) - McKinsey, נרשמה גישה בתאריך מרץ 17, 2026, https://www.mckinsey.com/~/media/mckinsey/dotcom/client_service/risk/pdfs/organizational%20health%20indexpsp.ashx
5. 12 Organizational Health Metrics HR Should Know - HR Curator, נרשמה גישה בתאריך מרץ 17, 2026, https://hrcurator.com/2023/03/06/12-organizational-health-metrics-hr-should-know/
6. Team Health Checks - by Philip Rogers - Medium, נרשמה גישה בתאריך מרץ 17, 2026, https://medium.com/agile-outside-the-box/team-health-checks-b4874c15bd73
7. Health Checks for Agile Teams - Scrum.org, נרשמה גישה בתאריך מרץ 17, 2026, https://www.scrum.org/resources/blog/health-checks-agile-teams
8. Benefits of Clinical Decision Support Systems for the Management of Noncommunicable Chronic Diseases: Targeted Literature Review, נרשמה גישה בתאריך מרץ 17, 2026, https://www.i-jmr.org/2024/1/e58036
9. Harnessing the power of clinical decision support systems: challenges and opportunities - PMC, נרשמה גישה בתאריך מרץ 17, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC10685930/
10. A Real-world Evaluation of a Case-based Reasoning Algorithm to Support Antimicrobial Prescribing Decisions in Acute Care - PubMed, נרשמה גישה בתאריך מרץ 17, 2026, https://pubmed.ncbi.nlm.nih.gov/32246143/
11. Case-based reasoning - Wikipedia, נרשמה גישה בתאריך מרץ 17, 2026, https://en.wikipedia.org/wiki/Case-based_reasoning
12. Mental disorders as networks of problems: a review of recent insights - PMC, נרשמה גישה בתאריך מרץ 17, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC5226976/
13. Network models of psychopathology and comorbidity: philosophical and pragmatic considerations - PubMed, נרשמה גישה בתאריך מרץ 17, 2026, https://pubmed.ncbi.nlm.nih.gov/20584378/
14. Full article: Coping and resilience in adults: a cross-sectional network analysis, נרשמה גישה בתאריך מרץ 17, 2026, https://www.tandfonline.com/doi/full/10.1080/10615806.2020.1772969

15. Resilience in Development and Psychopathology: Multisystem Perspectives, נרשמה גישה בתאריך מרץ 17, 2026, https://www.annualreviews.org/doi/10.1146/annurev-clinpsy-081219-120307
16. When Doing Wrong Feels So Right: Normalization of Deviance - PubMed, נרשמה גישה בתאריך מרץ 17, 2026, https://pubmed.ncbi.nlm.nih.gov/25742063/
17. Normalization of deviance - Wikipedia, נרשמה גישה בתאריך מרץ 17, 2026, https://en.wikipedia.org/wiki/Normalization_of_deviance
18. Normalization of Contestation: The Sociology of Knowledge and the Challenges to the Liberal International Order | Global Studies Quarterly | Oxford Academic, נרשמה גישה בתאריך מרץ 17, 2026, https://academic.oup.com/isagsq/article/4/2/ksae020/7655929
19. Normalization of Deviance - Patient Safety Concepts - Westgard QC, נרשמה גישה בתאריך מרץ 17, 2026, https://westgard.com/lessons/patient-safety-concepts/normal-lab-deviance.html
20. The Normalization of Deviance: The Definitive Encyclopedia of Why Great Companies Fail | by The QHSE Standard | Medium, נרשמה גישה בתאריך מרץ 17, 2026, https://medium.com/@qhsestandard/the-normalization-of-deviance-the-definitive-encyclopedia-of-why-great-companies-fail-c6156f6d1e8e
21. The Definitive Guide to Psychological Safety in the Workplace (2024–2025 Edition), נרשמה גישה בתאריך מרץ 17, 2026, https://influencejournalforleaders.com/2025/04/30/the-definitive-guide-to-psychological-safety-in-the-workplace/
22. Psychological safety in the changing workplace: Work in America 2024, נרשמה גישה בתאריך מרץ 17, 2026, https://www.apa.org/pubs/reports/work-in-america/2024/psychological-safety
23. Introduction and background - Assets - Cambridge University Press, נרשמה גישה בתאריך מרץ 17, 2026, https://assets.cambridge.org/97805217/17724/excerpt/9780521717724_excerpt.pdf
24. Four challenges for a theory of informational privacy, נרשמה גישה בתאריך מרץ 17, 2026, https://law.shu.edu/documents/floridi-luciano-fourchallenges.pdf
25. Neuro-Linguistic AI: Exploring the Cognitive Interface Between Human Language and Machine Understanding - Anusandhanvallari, נרשמה גישה בתאריך מרץ 17, 2026, https://psvmkendra.com/index.php/journal/article/download/954/790/1844
26. The Epistemic Suite: A Post-Foundational Diagnostic Methodology for Assessing AI Knowledge Claims - arXiv, נרשמה גישה בתאריך מרץ 17, 2026, https://arxiv.org/pdf/2510.24721
27. Argyris Single- and Double-Loop Learning model, נרשמה גישה בתאריך מרץ 17, 2026, https://umbrex.com/resources/frameworks/organization-frameworks/argyris-single-and-double-loop-learning-model/
28. Double-loop learning - Wikipedia, נרשמה גישה בתאריך מרץ 17, 2026, https://en.wikipedia.org/wiki/Double-loop_learning
29. Decision Latency Index (DLI) - The Agile Brand Guide®, נרשמה גישה בתאריך מרץ

2026 ,17, https://agilebrandguide.com/wiki/metrics/decision-latency-index-dli/
30. What is Decision Latency? The Hidden Cost Killing Your Operations | by Matt Sheehan, 2026 ,17 נרשמה גישה בתאריך מרץ, https://medium.com/@mattsheehan7365/what-is-decision-latency-the-hidden-cost-killing-your-operations-5886189caf46
31. Case-based reasoning for classification in the mixed data sets employing the compound distance methods | Request PDF - ResearchGate, נרשמה גישה בתאריך מרץ 17, 2026, https://www.researchgate.net/publication/260336675_Case-based_reasoning_for_classification_in_the_mixed_data_sets_employing_the_compound_distance_methods
32. Full article: A case-based reasoning system for interior design using a new cosine similarity retrieval algorithm - Taylor & Francis, 2026 ,17 נרשמה גישה בתאריך מרץ, https://www.tandfonline.com/doi/full/10.1080/24751839.2019.1700338
33. Full article: Symptom Networks and Associations with Quality of Life in Patients with Early to Mid-Stage Parkinson's Disease: A Network Analysis - Taylor & Francis, 2026 ,17 נרשמה גישה בתאריך מרץ, https://www.tandfonline.com/doi/full/10.2147/DNND.S535306
34. The Ultimate Guide to using PGVector | by Issa Hammoud - Medium, נרשמה גישה בתאריך מרץ 17, 2026, https://medium.com/@intuitivedl/the-ultimate-guide-to-using-pgvector-76239864bbfb
35. FAISS vs pgvector | Vector Database Comparison - Zilliz, נרשמה גישה בתאריך מרץ 17, 2026, https://zilliz.com/comparison/faiss-vs-pgvector
36. pgvector similarity search: Basics, tutorial and best practices, נרשמה גישה בתאריך מרץ 17, 2026, https://www.instaclustr.com/education/vector-database/pgvector-similarity-search-basics-tutorial-and-best-practices/
37. Enhancing Table Representations with LLM-powered Synthetic Data Generation - arXiv, 2026 ,17 נרשמה גישה בתאריך מרץ, https://arxiv.org/html/2411.03356v1
38. Transformers for Tabular Data Representation: A Survey of Models and Applications, 2026 ,17 נרשמה גישה בתאריך מרץ, https://direct.mit.edu/tacl/article/doi/10.1162/tacl_a_00544/115239/Transformers-for-Tabular-Data-Representation-A
39. How to handle similarity search on mixed data types vectors?, נרשמה גישה בתאריך מרץ 17, 2026, https://datascience.stackexchange.com/questions/120911/how-to-handle-similarity-search-on-mixed-data-types-vectors
40. What Is Cosine Similarity? | IBM, 2026 ,17 נרשמה גישה בתאריך מרץ, https://www.ibm.com/think/topics/cosine-similarity
41. Convex Clustering of Mixed Numerical and Categorical Data - Erasmus University Thesis Repository, 2026 ,17 נרשמה גישה בתאריך מרץ, https://thesis.eur.nl/pub/59464/Final_Version_Master_Thesis_Thomas_Brink.pdf
42. Mastering Similarity Metrics for Lookalike Modelling | by Vinícius Ramos - Medium, 2026 ,17 נרשמה גישה בתאריך מרץ,

https://viniciusarz.medium.com/mastering-similarity-metrics-for-lookalike-modelling-67e43729ace8
43. Clustering and Similarity Learning in Financial Markets: A Tutorial for the Practitioners, 2026 ,17 נרשמה גישה בתאריך מרץ, https://www.pm-research.com/content/iijpormgmt/52/2/150
44. Best Vector Databases in 2026: A Complete Comparison Guide - Firecrawl, 2026 ,17 נרשמה גישה בתאריך מרץ, https://www.firecrawl.dev/blog/best-vector-databases
45. Vector Database Comparison: Weaviate, Milvus, and Qdrant | Fountain Voyage, 2026 ,17 נרשמה גישה בתאריך מרץ, https://www.zair.top/en/post/vector-database-compare/
46. The Achilles Heel of Vector Search: Filters - Bits & Backprops, נרשמה גישה בתאריך מרץ 17, 2026, https://yudhiesh.github.io/2025/05/09/the-achilles-heel-of-vector-search-filters/
47. Super Powering our Freelancer Recommendation System using a Vector Database, 2026 ,17 נרשמה גישה בתאריך מרץ, https://blog.malt.engineering/super-powering-our-freelancer-recommendation-system-using-a-vector-database-add643fcfd23
48. pgvector vs FAISS · Issue #3 - GitHub, 2026 ,17 נרשמה גישה בתאריך מרץ, https://github.com/pgvector/pgvector/issues/3
49. How to Build Human-in-the-Loop Oversight for AI Agents | Galileo, נרשמה גישה בתאריך מרץ 17, 2026, https://galileo.ai/blog/human-in-the-loop-agent-oversight
50. LLM Embeddings for Deep Learning on Tabular Data - arXiv, נרשמה גישה בתאריך מרץ 17, 2026, https://arxiv.org/html/2502.11596v1
51. Human in the Loop (HITL) in Practice: A Guide to Core HITL Concepts, Benefits, and Effective AI Collaboration | Splunk, 2026 ,17 נרשמה גישה בתאריך מרץ, https://www.splunk.com/en_us/blog/learn/human-in-the-loop-ai.html
52. Human-in-the-loop evaluation: Combining expert review and metrics for trustworthy AI, 2026 ,17 נרשמה גישה בתאריך מרץ, https://medium.com/@khayyam.h/human-in-the-loop-evaluation-combining-expert-review-and-metrics-for-trustworthy-ai-08633fe4e078
53. Bayesian Calibration - What, Why And How - Purdue e-Pubs, נרשמה גישה בתאריך מרץ 17, 2026, https://docs.lib.purdue.edu/cgi/viewcontent.cgi?article=1166&context=ihpbc
54. Bayesian logistic regression for online recalibration and revision of risk prediction models with performance guarantees - PMC, 2026 ,17 נרשמה גישה בתאריך מרץ, https://pmc.ncbi.nlm.nih.gov/articles/PMC9006691/
55. Bayesian methods for calibrating health policy models: a tutorial - PMC, נרשמה גישה בתאריך מרץ 17, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC5448142/
56. Dynamic feedback loops in recommender systems: Analyzing fairness, popularity bias, and user group disparities - ResearchGate, ,17 נרשמה גישה בתאריך מרץ 2026, https://www.researchgate.net/publication/399768787_Dynamic_feedback_loops_in_recommender_systems_Analyzing_fairness_popularity_bias_and_user_group_disparities

57. Handling Feedback Loops in Recommender Systems - Deep Bayesian Bandits, נרשמה גישה בתאריך מרץ 17, 2026, https://towardsdatascience.com/handling-feedback-loops-in-recommender-systems-deep-bayesian-bandits-e83f34e2566a/
58. Optimizing filtered vector queries from tens of seconds to single-digit milliseconds in PostgreSQL : r/Python - Reddit, נרשמה גישה בתאריך מרץ 17, 2026, https://www.reddit.com/r/Python/comments/1ooy326/optimizing_filtered_vector_queries_from_tens_of/
59. Case-Based Reasoning: Foundational Issues, Methodological Variations, and System Approaches - IIIA-CSIC, נרשמה גישה בתאריך מרץ 17, 2026, https://www.iiia.csic.es/~enric/papers/AICom.pdf